

Problema de Atribuição de Leads Comerciais em uma Startup de Impacto: Uma Abordagem de Otimização Combinatória para Maximização de Retorno

Leandro Dos Santos Cesar
Leon Lourenço da Silva Santos
Vithoria Camila Bastos da Silva

Universidade Federal Rural de Pernambuco (UFRPE)

Tópicos em Otimização

Junho de 2026

Resumo

A questão que motiva este trabalho é direta: como alocar o tempo da equipe comercial sobre os leads disponíveis de forma a maximizar a receita esperada total? A Biofábrica de Corais (BFC), startup de restauração de recifes com funil comercial ativo em plataforma CRM, conta com três vendedores e capacidade limitada de atendimento por ciclo. A partir de 113 registros reais de leads, modelamos o problema como uma mochila binária e como um grafo bipartido ponderado, e comparamos três abordagens de solução: heurística gulosa (Greedy), programação dinâmica (Knapsack 0/1) e matching de peso máximo (algoritmo Húngaro). Nos 37 leads ativos, a demanda total de atendimento (72,5 horas) excede a capacidade disponível (60 horas), tornando a seleção dos leads uma decisão de otimização real. O Knapsack 0/1 chegou à solução ótima com 31 leads e valor esperado de R\$ 24.727,40, enquanto o Greedy alocou 30 leads (R\$ 24.669,00) e o Matching Bipartido, restrito à cota individual de cada vendedor, atingiu o mesmo resultado do Greedy com distribuição equilibrada entre todos os três vendedores. O artigo discute as implicações práticas dos resultados e as limitações decorrentes da qualidade dos dados coletados no CRM.

Palavras-chave: alocação de leads; mochila binária; matching bipartido; otimização combinatória; funil comercial.

Sumário

1	Introdução	3
2	Objetivos	3
3	Metodologia	4
3.1	Formulação do Problema	4
3.2	Modelos de Otimização	4
3.2.1	Mochila Binária (0/1 Knapsack)	4
3.2.2	Matching de Peso Máximo em Grafo Bipartido	5
3.3	Algoritmos Implementados	5
3.3.1	Greedy por Eficiência	5
3.3.2	Knapsack 0/1 via Programação Dinâmica	5
3.3.3	Matching Bipartido: Algoritmo Húngaro	5
3.4	Estimativa dos Parâmetros	6
4	Dados	6
4.1	Base de Dados	6
4.2	Completude e Qualidade	7
4.3	Distribuição da Probabilidade de Conversão	8
4.4	O Grafo Bipartido	8
4.5	Análise por Vendedor	9
4.6	Os Leads Ativos	10
5	Simulações	10
5.1	Configuração	10
5.2	Resultados	11
5.3	Interpretação dos Resultados	11
6	Conclusão	13
	Referências	14

1 Introdução

Toda equipe comercial enfrenta, a cada ciclo de trabalho, uma decisão de alocação: quais leads abordar, em que ordem e por qual vendedor. Quando o número de leads supera a capacidade de atendimento da equipe, escolher mal significa deixar dinheiro na mesa. Escolher bem, por outro lado, é um problema de otimização.

A Biofábrica de Corais (BFC) é uma startup de impacto social voltada à restauração de recifes de corais e à educação ambiental. Seu processo comercial é gerenciado no CRM Monday.com e envolve produtos de perfis variados: de associações individuais a projetos PDI e ESG com organizações de maior porte. A equipe conta com três vendedores e um volume de leads ativos que varia entre 20 e 80 por ciclo.

A questão central que motiva este trabalho é:

Como alocar o tempo da equipe comercial sobre os leads disponíveis de forma a maximizar a receita esperada total?

Para responder a essa questão, formalizamos o problema por meio de dois modelos clássicos de otimização combinatória: a mochila binária e o matching em grafo bipartido. Os modelos foram aplicados sobre dados reais extraídos do CRM da BFC. Os resultados permitem não apenas identificar a alocação ótima para o ciclo atual, mas também compreender como a qualidade dos dados de entrada afeta a confiabilidade da solução.

2 Objetivos

O objetivo geral deste trabalho é determinar, por meio de modelos formais de otimização, quais leads devem ser priorizados pela equipe comercial da BFC a fim de maximizar a receita esperada dentro da capacidade de atendimento disponível.

De forma específica, busca-se:

- i. Modelar o problema de atribuição de leads como mochila binária (seleção de subconjunto sujeita a restrição de capacidade) e como grafo bipartido ponderado (atribuição de leads a vendedores).
- ii. Implementar três algoritmos de solução: Greedy por eficiência, Knapsack 0/1 via programação dinâmica e Matching Bipartido pelo método Húngaro.
- iii. Aplicar os modelos sobre os dados reais da BFC e comparar os resultados em termos de valor esperado capturado, leads alocados e utilização de capacidade.
- iv. Discutir as limitações do modelo frente à qualidade dos dados disponíveis e indicar o que seria necessário para calibrá-lo de forma mais precisa.

3 Metodologia

3.1 Formulação do Problema

Seja $L = \{l_1, l_2, \dots, l_n\}$ o conjunto de leads ativos e $V = \{v_1, v_2, \dots, v_m\}$ o conjunto de vendedores disponíveis em um ciclo de atendimento. Associamos a cada lead l_i um peso:

$$w_i = p_c(l_i) \times V_t(l_i) \quad (1)$$

onde $p_c(l_i) \in [0, 1]$ é a probabilidade estimada de conversão e $V_t(l_i)$ é o valor monetário esperado do contrato caso o lead converta. O produto w_i é, portanto, a receita esperada de abordar o lead l_i .

Cada lead demanda t_i horas de atendimento. A capacidade de cada vendedor por ciclo é C_j horas. O objetivo é selecionar quais leads atender e a qual vendedor atribuir cada um, de modo a maximizar a receita esperada total sem ultrapassar a capacidade disponível.

A relação completa entre leads e vendedores é representada como um grafo bipartido $G = (L, V, E)$, onde cada aresta $(l_i, v_j) \in E$ possui peso:

$$w(l_i, v_j) = p_c(l_i) \times V_t(l_i) \times A(l_i, v_j) \quad (2)$$

O fator $A(l_i, v_j) \in [0, 1]$ captura a afinidade entre o perfil do lead e o vendedor. Por exemplo, um vendedor com histórico em clientes do setor público tende a converter melhor leads desse perfil. Na ausência de dados históricos suficientes para estimá-lo, adotamos $A = 1$ para todas as arestas.

3.2 Modelos de Otimização

3.2.1 Mochila Binária (0/1 Knapsack)

O primeiro enquadramento trata o problema como uma mochila binária: dado um conjunto de n leads, cada um com valor esperado w_i e custo de atendimento t_i , e uma capacidade total de tempo $C = \sum_{j=1}^m C_j$, selecionar o subconjunto $S \subseteq L$ que resolve:

$$\max_{S \subseteq L} \sum_{l_i \in S} w_i \quad \text{sujeito a} \quad \sum_{l_i \in S} t_i \leq C \quad (3)$$

Esta formulação responde diretamente à questão central: quais leads devem ser abordados para maximizar a receita esperada total, dado o tempo disponível da equipe

como um todo.

3.2.2 Matching de Peso Máximo em Grafo Bipartido

O segundo enquadramento distribui cada lead a um vendedor específico, respeitando a capacidade individual C_j de cada um. O objetivo é encontrar um matching $M \subseteq E$ que maximize $\sum_{(l_i, v_j) \in M} w(l_i, v_j)$ sujeito a $\sum_{l_i \in M_j} t_i \leq C_j$ para todo v_j , onde M_j é o conjunto de leads atribuídos ao vendedor v_j .

Esta formulação responde à pergunta em sua versão mais completa: não apenas *quais* leads abordar, mas *quem* deve atender *qual* lead.

3.3 Algoritmos Implementados

3.3.1 Greedy por Eficiência

A heurística gulosa ordena os leads de forma decrescente pela razão $e_i = w_i/t_i$ (receita esperada por hora de atendimento) e os seleciona sequencialmente até esgotar a capacidade total. Sua complexidade é $O(n \log n)$. Apesar de não garantir o ótimo em todos os casos, oferece solução próxima e pode ser executada em tempo real mesmo com funis grandes.

3.3.2 Knapsack 0/1 via Programação Dinâmica

A solução exata do problema (3) é obtida por programação dinâmica. Discretizamos o tempo em unidades de 0,5 hora, resultando em $C' = C/0,5$ estados possíveis. A tabela $dp[c]$ armazena o maior valor alcançável com capacidade c . Complexidade $O(n \cdot C')$.

3.3.3 Matching Bipartido: Algoritmo Húngaro

O matching de peso máximo no grafo G é resolvido pelo algoritmo Húngaro [1], implementado via `scipy.optimize.linear_sum_assignment`. Cada vendedor recebe um número de slots proporcional à sua capacidade dividida pelo menor tempo de atendimento do conjunto. O algoritmo minimiza o custo negativo, equivalendo a maximizar a receita esperada.

A Tabela 1 resume as três abordagens.

Tabela 1: Comparativo de complexidade dos algoritmos implementados.

Algoritmo	Pergunta respondida	Complexidade	Otimalidade
Greedy	Quais leads? (heurística)	$O(n \log n)$	Aprox.
Knapsack PD	Quais leads? (exato)	$O(n \cdot C')$	Exata
Alg. Húngaro	Quem atende quem?	$O(V^3)$	Exata

3.4 Estimativa dos Parâmetros

Probabilidade de conversão p_c . Na ausência de modelo preditivo calibrado, adotamos priors baseados no campo `interesse_nivel` registrado no CRM (Tabela 2). O decaimento exponencial por tempo no funil é aplicado quando o campo não está preenchido, resultando em prior mínimo de 0,10 para leads sem dado.

Tabela 2: Priors de p_c adotados por nível de interesse declarado.

Nível de interesse	p_c adotado	Sinal observado no CRM
Muito Alto	0,85	Lead perguntou data e horário disponíveis
Alto	0,65	Lead perguntou o preço
Moderado	0,55	Fechamento por indicação
Médio	0,45	Lead perguntou como funciona
Baixo	0,20	Lead perguntou o que é o produto
Sem dado	0,10	Prior mínimo por ausência de registro

Valor do contrato V_t . O campo de valor monetário no CRM tem completude de apenas 1%. Como proxy, adotamos medianas por segmento: R\$ 12.000 para pessoa jurídica (PJ) e R\$ 2.500 a R\$ 3.000 para pessoa física (PF).

Tempo de atendimento t . Estimativa da própria equipe: 3,0 horas para leads PJ e 1,5 horas para PF. Leads sem tipo definido recebem 2,0 horas.

Capacidade. Adotamos $C_j = 20$ horas por vendedor por ciclo, totalizando $C = 60$ horas para os três vendedores ativos.

4 Dados

4.1 Base de Dados

Os dados foram extraídos do CRM Monday.com da BFC em maio de 2026. O dataset `leads_master.csv` possui 113 registros e 21 atributos, particionados conforme a

Tabela 3.

Tabela 3: Partições do dataset de leads.

Partição	n	Descrição
Histórico	76	Leads com desfecho conhecido
Ativo	37	Leads em aberto, alvo da otimização
Total	113	

4.2 Completude e Qualidade

A Figura 1 mostra a completude por coluna. Campos derivados e identificadores atingem 100%, mas atributos críticos para o modelo permanecem com baixo preenchimento: `interesse_produto` (15%), `interesse_nivel` (30%) e data de início da negociação (35%). O campo de valor do contrato, central para o cálculo de w_i , possui apenas 1% de preenchimento com dado real, sendo o restante estimado por segmento.




Figura 1: Completude por coluna. Azul escuro: $\geq 80\%$; cinza: 50–79%; vermelho: $< 50\%$.

4.3 Distribuição da Probabilidade de Conversão

A distribuição de p_c nos 113 leads é bimodal (Figura 2): 41% dos leads recebem o prior mínimo de 0,10 por ausência de `interesse_nivel`, enquanto os demais se concentram entre 0,45 e 0,65. O contraste entre o subconjunto histórico (mediana 0,45) e o ativo (mediana 0,07) é expressivo: a maioria dos leads em aberto são leads “frios”, com baixa informação declarada.




Figura 2: Distribuição de p_c por fonte (esq.) e por partição do dataset (dir.).

4.4 O Grafo Bipartido

A Figura 3 ilustra a estrutura do grafo bipartido com cinco leads representativos e os três vendedores. A espessura de cada aresta é proporcional ao peso w_{ij} . O lead “Simone” (PJ, interesse Alto), com $w = \text{R\$ } 7.800$, destaca-se como a aresta mais espessa do grafo e estava, no momento do estudo, sem vendedor atribuído.




Figura 3: Representação esquemática do grafo bipartido $G = (L, V, E)$. Espessura da aresta proporcional ao peso $w_{ij} = p_c \cdot V_t$.

4.5 Análise por Vendedor

Dos 84 leads com responsável atribuído, Marcela Belo concentra 55% do volume (Figura 4). No histórico, ela também acumula o maior valor esperado total (R\$ 64.250). As taxas de conversão individuais devem ser interpretadas com cautela: o histórico registra 68 conversões e apenas 8 não conversões, o que não reflete a taxa real de fechamento. Leads não convertidos raramente têm o campo `interesse_nivel` preenchido e, por isso, raramente entram no registro com desfecho confirmado. Este viés de seleção faz com que o histórico subestime as perdas e superestime as taxas individuais.




Figura 4: Volume de leads, taxa de conversão e valor esperado acumulado por vendedor no subconjunto histórico.

4.6 Os Leads Ativos

A Figura 5 mostra a distribuição de w_i nos 37 leads ativos. A carteira é polarizada: 8 leads concentram valor $w \geq \text{R\$ } 500$ e respondem por 85,5% do valor esperado total (R\$ 21.724 de R\$ 25.391), enquanto os 29 leads restantes somam apenas 14,5%. O lead “Simone”, sozinho, representa 30,7% do valor total da carteira ativa.




Figura 5: Distribuição do valor esperado w_i nos leads ativos. Os 8 leads com $w \geq \text{R\$ } 500$ concentram 85,5% do valor total.

5 Simulações

5.1 Configuração

Os três algoritmos foram aplicados sobre os 37 leads ativos. A Tabela 4 resume os parâmetros do experimento.

Tabela 4: Parâmetros das simulações.

Parâmetro	Valor
Leads ativos (n)	37
Vendedores (m)	3
Capacidade por vendedor (C_j)	20 h
Capacidade total (C)	60 h
Tempo total requerido ($\sum t_i$)	72,5 h
Valor esperado máximo ($\sum w_i$)	R\$ 25.391,75

Um aspecto estrutural do cenário atual merece atenção: o tempo total necessário para atender todos os leads ativos (72,5 h) excede a capacidade total disponível (60 h). Isso

significa que a restrição é vinculante e a questão de otimização é genuinamente relevante: é preciso escolher *quais* leads atender e como distribuir a carga entre os vendedores para maximizar o valor esperado capturado.

5.2 Resultados

A Tabela 5 e a Figura 6 sintetizam os resultados dos três algoritmos.

Tabela 5: Resultados comparativos dos algoritmos de otimização.

Algoritmo	Leads alocados	Valor esp. (R\$)	Tempo (h)	Captura (%)
Greedy	30	24.669,00	59,0	97,2
Knapsack 0/1	31	24.727,40	60,0	97,4
Matching Bipartido	30	24.669,00	59,0	97,2
Valor máximo possível		R\$ 25.391,75	72,5 h	




Figura 6: Comparativo dos algoritmos: leads alocados, valor esperado capturado e utilização da capacidade total.

5.3 Interpretação dos Resultados

Knapsack supera o Greedy. Com a restrição de capacidade vinculante ($60 \text{ h} < 72,5 \text{ h}$ requeridas), os dois algoritmos divergem. O Knapsack 0/1, por explorar exaustivamente as combinações via programação dinâmica, aloca 31 leads e captura R\$ 24.727,40 (97,4% do valor máximo possível). O Greedy, que ordena por eficiência w_i/t_i e aloca sequencialmente, obteve 30 leads e R\$ 24.669,00, ficando R\$ 58,40 abaixo do ótimo. A diferença é pequena neste cenário, mas ilustra por que a heurística gulosa não garante otimalidade quando a restrição é ativa.

O Matching Bipartido distribui a carga de forma equilibrada. O algoritmo Húngaro respeita a capacidade individual de 20 h por vendedor e aloca 30 leads, obtendo R\$ 24.669,00 (97,2% do máximo). Com apenas três vendedores, todos tiveram suas agendas praticamente preenchidas (Figura 7), tornando o Matching a solução mais equilibrada e operacionalmente realista. O custo em relação ao Knapsack é de apenas R\$ 58,40, valor marginal diante da vantagem de distribuição equitativa.




Figura 7: Utilização da capacidade por vendedor no Matching Bipartido. Todos os três vendedores operam próximos do limite de 20 h.

O lead de maior valor está sem vendedor. “Simone” (PJ, interesse Alto, $w = \text{R\$ } 7.800$, eficiência de $\text{R\$ } 2.600/\text{hora}$) é o lead prioritário de toda a carteira ativa. Em todos os três algoritmos ele é o primeiro a ser alocado. O fato de estar sem vendedor atribuído no momento do estudo é o achado mais imediato desta análise e pode ser corrigido sem nenhum ajuste no modelo.

Resposta à questão central. Com base nas simulações, a resposta para “como alocar o tempo da equipe comercial sobre os leads disponíveis de forma a maximizar a receita esperada total?” é:

1. Atribuir imediatamente “Simone” (PJ, Alto) a um vendedor disponível. Este lead, sozinho, representa 30,7% do valor esperado da carteira ativa.
2. Usar o Knapsack 0/1 como critério de seleção: com 60 h disponíveis para 72,5 h de demanda, o algoritmo identifica os 31 leads de maior valor esperado que cabem na capacidade, capturando 97,4% do valor possível.
3. Na distribuição entre vendedores, priorizar os 8 leads com $w \geq \text{R\$ } 500$ para os vendedores de maior taxa histórica de conversão, reservando o restante para completar as agendas.

4. Adotar o Matching Bipartido como modelo de distribuição quando a equidade de carga for relevante, aceitando a perda de até 10% do valor esperado em troca de uma distribuição mais equilibrada.

6 Conclusão

Este trabalho partiu de uma questão prática: como alocar o tempo de uma equipe comercial para maximizar a receita esperada. A resposta foi construída por meio de modelos formais de otimização combinatória aplicados sobre dados reais de uma startup de impacto.

Os principais resultados são:

- i. No cenário atual, com capacidade total de 60 h e demanda de 72,5 h, o Knapsack 0/1 entrega a solução ótima: 31 leads com valor esperado de R\$ 24.727,40 (97,4% do valor máximo possível).
- ii. A maior oportunidade imediata é o lead “Simone” (PJ, Alto interesse), que representa 30,7% do valor esperado da carteira e está sem vendedor atribuído. Corrigir essa lacuna não requer nenhum ajuste de modelo.
- iii. O Matching Bipartido distribui os 30 leads de forma equitativa entre os três vendedores, com todos operando próximos do limite de 20 h. O custo em relação ao Knapsack é de R\$ 58,40, valor marginal diante da vantagem operacional de distribuição equilibrada.
- iv. A principal limitação do modelo é a qualidade dos dados: 99,1% dos valores de contrato são estimativas por segmento, 41% dos leads usam o prior mínimo de p_c e o fator de afinidade $A(l_i, v_j)$ não pode ser calculado por falta de histórico estratificado. Os resultados são corretos dado o modelo, mas o modelo é tão bom quanto os dados que o alimentam.

Para que o modelo se torne progressivamente mais preciso, três ações são necessárias: tornar obrigatório o preenchimento do valor do contrato no CRM; registrar o tempo real de atendimento por lead; e acumular histórico de conversão estratificado por vendedor e tipo de produto, o que permitirá calcular $A(l_i, v_j)$ e substituir os priors manuais de p_c por estimativas empíricas.

Referências

Referências

- [1] Kuhn, H. W. (1955). The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2):83-97.
- [2] Dantzig, G. B. (1957). Discrete-variable extremum problems. *Operations Research*, 5(2):266-277.
- [3] Kellerer, H., Pferschy, U., e Pisinger, D. (2004). *Knapsack Problems*. Springer, Berlin.
- [4] Cormen, T. H., Leiserson, C. E., Rivest, R. L., e Stein, C. (2009). *Introduction to Algorithms*, 3. ed. MIT Press, Cambridge, MA.
- [5] West, D. B. (2001). *Introduction to Graph Theory*, 2. ed. Prentice Hall, Upper Saddle River, NJ.
- [6] Virtanen, P. et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17:261-272.