

Universidade Federal Rural de Pernambuco

Tópicos em Otimização

Explorando dados

Docente: Claudio Tadeu Cristino

Discentes:

Leandro Dos Santos Cesar

Leon Lourenço dos Santos

Vithória Camila da Silva Bastos

Recife, 2025

1. Obtenção, Descrição e Incerteza dos Dados

Os dados utilizados neste projeto foram extraídos diretamente do sistema de CRM da Biofábrica de Corais, operado na plataforma Monday.com. O board de referência é o *QDR-MKT.LEA-001 — Triagem Leads & Negociação Bio Cliente*, identificado internamente pelo ID `9635579330`, que continha 1.595 itens cadastrados no momento da extração. A coleta foi realizada via API GraphQL do Monday.com, que devolve os atributos de cada lead em formato JSON estruturado, convertido em seguida para um dataset tabular único.

O resultado da extração e do tratamento é o arquivo `leads_master.csv`, com 113 linhas e 21 colunas. Uma coluna chamada `particao` distingue dois subconjuntos dentro do mesmo arquivo: **76 leads históricos** (com desfecho conhecido, status Fechou Ganho ou Não Fechou) e **37 leads ativos** (status Em Negociação ou Não Iniciado, sem desfecho). Essa separação em partições dentro de um único arquivo, em vez de em arquivos distintos, garante que as features sejam idênticas entre treino e inferência, eliminando risco de desalinhamento de colunas em usos futuros.

Um segundo arquivo, o `dicionario_dados.csv`, documenta cada uma das 21 colunas com tipo de dado, descrição, valores possíveis, exemplo concreto, fonte do dado, completude estimada e observações críticas. Esse dicionário é parte integral do dataset: qualquer análise futura deve consultá-lo antes de interpretar as colunas, especialmente as que contêm estimativas em vez de medições reais.

Dimensão	Partição histórico	Partição ativo
Total de registros	76 leads	37 leads
Rótulo de conversão (converteu)	0 = Não Fechou: 8 leads (10,5%) / 1 = Fechou Ganho: 68 leads (89,5%)	NULL — resultado ainda desconhecido
Interesse declarado preenchido	59 leads (77,6%)	8 leads (21,6%)
Valor de contrato real no CRM	1 lead (1,3%) — R\$ 1.000	0 leads (0%)
Responsável atribuído	69 leads (90,8%)	15 leads (40,5%)
Qualidade Alta / Média / Baixa	0% / 77,6% / 22,4%	0% / 21,6% / 78,4%

Tabela 1 — Resumo do dataset `leads_master.csv` nas duas partições.

1.1 Granularidade dos Dados

A unidade de análise é o **lead individual**. Cada linha representa um único contato ou organização no funil comercial, com seus atributos no momento da extração. Essa granularidade é adequada para o modelo de otimização proposto, pois o algoritmo precisa avaliar e ranquear cada lead separadamente para compor a lista de atribuições da equipe.

O que o dataset não captura são os eventos de interação dentro de cada lead: ligações realizadas, mensagens enviadas, reuniões agendadas, objeções levantadas. Esse nível mais fino existe no Monday.com na forma de subelementos e atualizações de cada item, mas não foi extraído nesta versão. A consequência prática é que o modelo não consegue distinguir um lead

Em Negociação que recebeu cinco tentativas de contato sem resposta de outro que está em processo ativo de proposta. Os dois aparecem com o mesmo status no dataset.

Para o modelo de otimização funcionar bem a curto prazo, a granularidade de lead é suficiente. Para um modelo preditivo de machine learning mais sofisticado no futuro, será necessário incorporar a granularidade de evento, o que representa um salto significativo na complexidade da engenharia de dados.

1.2 Descrição Temporal

O dataset representa um **corte transversal** do CRM em 29 de maio de 2026, data de referência para todos os cálculos temporais. Não é uma série temporal: não há múltiplas observações de um mesmo lead ao longo do tempo. Cada lead aparece uma única vez, com o estado que tinha nessa data.

Ainda assim, há uma dimensão temporal capturada em três colunas. A coluna `data_criacao` registra quando o lead entrou no sistema. A coluna `data_inicio_negociacao`, quando preenchida, marca o início formal do acompanhamento comercial. A coluna `dias_no_funil` é calculada como a diferença entre a data de referência e a data de criação, representando o envelhecimento do lead. Esses três campos constroem uma noção de urgência que o modelo usa diretamente: leads com muitos dias no funil e sem interesse declarado recebem um decaimento na probabilidade de conversão estimada, pela função $Pc_{aj} = Pc \times \exp(-0,01 \times dias)$, aplicada quando o campo de interesse está vazio e o lead acumula mais de 30 dias sem registro de ação.

O histórico abrange o período de setembro de 2025 a maio de 2026, aproximadamente oito meses de operação registrada. Esse intervalo é curto para fins de calibração estatística, mas é o dado real disponível. A distribuição dos leads ao longo desse período não é uniforme: há concentrações em novembro de 2025 e entre março e abril de 2026, que correspondem a eventos comerciais e campanhas pontuais da BFC.

1.3 Erros de Medida e Incerteza

O contexto geral de dados de CRM

Dados de CRM são inerentemente ruidosos porque dependem de preenchimento humano, realizado sob pressão de tempo e sem incentivo direto à qualidade. O campo de valor de contrato fica em branco porque o vendedor está focado em fechar a negociação, não em documentar. O nível de interesse fica vazio porque foi inferido em uma conversa informal e nunca formalizado no sistema. Esse padrão é universal em sistemas de vendas em estágio inicial e não é uma particularidade da BFC.

A incerteza nos dados pode ser classificada em dois tipos com consequências distintas para o modelo. A **incerteza epistêmica** é aquela que poderia ser reduzida com mais dados ou com melhor disciplina de preenchimento: se a equipe registrar sistematicamente o valor de cada proposta e o tempo gasto por atendimento, esses parâmetros se tornam mensuráveis e o modelo ganha precisão com o tempo. A **incerteza aleatória** é irreduzível e inerente ao fenômeno: mesmo conhecendo todos os atributos de um lead, existe uma componente de imprevisibilidade no comportamento de compra que nenhum modelo eliminará completamente.

Fontes específicas de erro neste dataset

A variável `interesse_nivel`, principal proxy para a probabilidade de conversão P_c , apresenta um viés de seleção grave. O campo foi preenchido principalmente quando o lead recebeu atenção da equipe. Leads que foram perdidos por abandono ou falta de resposta raramente tiveram seus atributos registrados. O resultado é que a taxa de conversão observada no histórico chega a 89,5%, um valor completamente distorcido da realidade do funil. Os priors de P_c adotados no modelo foram calibrados de forma conservadora para compensar esse viés, mas a calibração real só será possível quando o histórico tiver volume e qualidade suficientes.

A variável `vt_estimado_RS` é real em apenas 1 dos 113 registros: R\$ 1.000 de uma negociação PJ. Para todos os demais, o valor foi estimado por segmento (R\$ 12.000 para leads PJ e R\$ 2.500 para leads PF), baseado em mediana aproximada da equipe comercial. Esses valores afetam diretamente o peso da aresta $w = P_c \times V_t$, que é o critério central do algoritmo. Um lead PJ com valor real de R\$ 50.000 seria ranqueado de forma completamente diferente com V_t real do que com a estimativa de R\$ 12.000.

A variável `t_atendimento_h` não existe como medição real em nenhuma parte do sistema atual. O valor de 3 horas para leads PJ e 1,5 hora para leads PF é uma estimativa consensual da equipe, sem registro histórico que a sustente. Essa é a lacuna mais crítica para a restrição de capacidade do modelo Knapsack, pois a seleção de quais leads abordar depende diretamente de quão preciso é o custo de cada atendimento.

Há também problemas de qualidade na entrada dos dados brutos. Nomes como "Contato" (repetido 13 vezes no board), "lizi" e "Bruno" sem sobrenome indicam registros incompletos. O nome "Eduardo Akira" aparece duas vezes no histórico com datas distintas. Esses casos não invalidam o dataset para fins acadêmicos e de prototipagem, mas precisarão de tratamento antes de qualquer uso em produção.

Variável	Tipo	Origem do problema	Completo atual	Gravidade
<code>interesse_nivel</code>	Epistêmica + viés	Campo preenchido só em leads atendidos. Taxa 89,5% é artefato.	78% hist / 22% ativ	Alta
<code>vt_estimado_RS</code>	Epistêmica	Campo não obrigatório; negociação avança sem registro de valor.	1% com dado real	Alta
<code>t_atendimento_h</code>	Epistêmica	Não existe cronometragem. Valor por consenso sem base empírica.	0% real	Alta
<code>A (afinidade)</code>	Epistêmica (subjetiva)	Conhecimento tácito; sem critério documentado no CRM.	Campo inexistente	Média
<code>status_funil</code>	Aleatória	Atualização manual pode atrasar dias ou semanas.	100% preenchido	Baixa
<code>tipo_cliente</code>	Epistêmica	Preenchimento inconsistente; não obrigatório no formulário.	66% hist / 49% ativ	Média

Tabela 2 — Fontes de incerteza por variável e avaliação de gravidade para o modelo.

1.4 Prontidão dos Dados para Uso

É importante distinguir dois contextos de uso para os dados coletados, pois a resposta sobre prontidão é diferente em cada caso.

Para o **modelo de otimização** descrito nos capítulos anteriores (heurística Greedy, Knapsack via programação dinâmica ou Algoritmo Húngaro), o dataset está pronto para uso imediato. As colunas `pc_estimado`, `vt_estimado_RS`, `t_atendimento_h` e `eficiencia_w_t` já estão em formato numérico e podem ser passadas diretamente ao algoritmo. O ranking gerado terá limitações decorrentes das incertezas documentadas, mas é funcional e representa um critério melhor do que a ausência de priorização formal.

Para o **treinamento de um modelo de machine learning supervisionado** (por exemplo, regressão logística ou gradient boosting para prever a coluna `converteu`) o dataset atual não está pronto. Quatro problemas estruturais impedem o uso direto: (a) 76 registros históricos são insuficientes para qualquer algoritmo de aprendizado produzir generalizações confiáveis; (b) o desbalanceamento de 89,5% positivos, com viés de seleção grave, tornaria qualquer modelo treinado tendencioso para prever conversão indiscriminadamente; (c) variáveis categóricas precisam de codificação (one-hot ou ordinal) antes de entrar em algoritmos de ML; (d) a feature central `interesse_nivel` está ausente em 78% dos leads ativos, exigindo uma estratégia de imputação explícita. O caminho para a prontidão em ML passa por acumular pelo menos 500 registros históricos com desfecho conhecido, tornar obrigatório o preenchimento de interesse e valor no momento do fechamento ou perda, e iniciar um registro de tempo de atendimento por tipo de lead. Esse processo leva entre seis e doze meses de operação disciplinada do CRM.

1.5 Cenários Alternativos de Aplicação

O modelo foi concebido para um cenário específico: priorização de leads em um único ciclo comercial com equipe e capacidade fixas. A estrutura do dataset e do grafo bipartido é suficientemente flexível, porém, para suportar variações relevantes.

Cenário A — Otimização por Segmento de Interesse

Em vez de um ranking único de todos os leads, o algoritmo pode ser executado separadamente por produto de interesse: um ranking para leads de Turismo Regenerativo, outro para Adoção de Corais, outro para Projetos PDI e ESG. Cada segmento teria seu vetor de parâmetros (P^c , V_t , t) calibrado com base no histórico daquele segmento. O campo `interesse_produto` já existe no dataset com 15% de preenchimento nos ativos, o que é suficiente para uma primeira execução segmentada.

Cenário B — Análise de Sensibilidade ao Valor de Contrato

Como o campo de valor de contrato é quase inteiramente estimado, o algoritmo pode ser executado com três cenários de V_t (pessimista, base e otimista) para verificar se os cinco leads prioritários permanecem estáveis. Leads que mantêm posição alta nos três cenários têm prioridade robusta. Leads que oscilam muito sinalizam que a decisão depende criticamente de informação ainda não coletada, e devem ser encaminhados para julgamento humano adicional. Esse cenário usa os dados exatamente como estão e não requer nenhuma coleta adicional.

Cenário C — Reserva de Capacidade para Leads Institucionais

Leads como EMBRATUR, SEBRAE STARTUPS e Escritório da OMPI no Brasil aparecem no dataset ativo com status Não Iniciado e parâmetros desconhecidos. São contratos potencialmente grandes com ciclos de venda muito mais longos que os leads PF típicos. O algoritmo greedy deprimirá automaticamente esses leads pela ausência de dado (P^c baixo) e pelo custo alto (t estimado para PJ). Uma extensão natural é reservar uma fração da

capacidade da equipe explicitamente para leads institucionais, tratando-os como uma restrição separada no modelo Knapsack.

Cenário D — Reotimização Contínua por Evento

Sempre que um vendedor registra uma nova interação no Monday.com, os atributos do lead se atualizam e o ranking pode mudar. Um script agendado para executar o algoritmo greedy a cada 24 horas garantiria que a lista de prioridades está sempre alinhada com o estado mais recente do funil. Esse cenário é simples de implementar com a infraestrutura já existente e aproveita diretamente a estrutura do dataset atual.

Cenário E — Modelo Preditivo com Histórico Acumulado

Com o crescimento do histórico e a melhoria do preenchimento do CRM, o valor fixo de P^c por categoria pode ser substituído por um modelo preditivo treinado sobre dados reais. Uma regressão logística com as features `interesse_nivel`, `tipo_cliente`, `dias_no_funil` e `interesse_produto` seria o ponto de partida natural, produzindo probabilidades de conversão individualizadas. O dataset atual já tem a estrutura certa para esse uso: a coluna `converteu` é o rótulo e as demais são as features. O que falta é volume de dados e qualidade de preenchimento, não arquitetura.

1.6 Síntese

Os dados coletados refletem com fidelidade o estado real de um funil comercial em estágio inicial: rico em estrutura e limitado em completude. A granularidade de lead é adequada para o modelo de otimização proposto. A dimensão temporal está presente por meio do envelhecimento dos leads e do histórico de conversões dos últimos oito meses. Os erros de medida são predominantemente epistêmicos e redutíveis com disciplina de preenchimento ao longo do tempo.

O ponto mais crítico para a interpretação dos resultados é o viés de seleção na variável de interesse: a taxa de conversão histórica de 89,5% é um artefato de como o CRM foi alimentado, não uma medida do desempenho real do funil. Os priors de P^c foram definidos com desconto conservador para compensar esse viés, e a calibração precisa só será possível quando o histórico atingir volume e qualidade suficientes.

Para o objetivo imediato deste trabalho, o conjunto de dados está em condição de uso. Para aplicação em machine learning supervisionado, o dataset atual serve como prova de conceito da arquitetura de dados, mas exigirá entre seis e doze meses de coleta adicional antes de suportar modelos preditivos estatisticamente robustos.